Análise de Resultados de Detecção conforme número de Épocas de Treinamento

Lara Santos Pereira Soares

INTRODUÇÃO

Para analisar os resultados de detecção conforme o número de épocas de treinamento de um modelo de rede neural Perceptron Multicamadas, é fundamental observar a evolução de duas métricas importantes ao longo das épocas.

1. Métricas de Avaliação

- **Acurácia (Accuracy):** Mede a porcentagem de classificações corretas em relação ao total de amostras. Ao longo das épocas, você espera que a acurácia aumente ou estabilize, indicando que o modelo está aprendendo a generalizar melhor.
- **Perda (Loss):** A perda é uma função que indica o quão distante as previsões do modelo estão das respostas corretas. Idealmente, a perda deve diminuir com o tempo.

1.1 Curvas de Aprendizado

- A análise das curvas de aprendizado é crucial para entender como o modelo está evoluindo durante o treinamento. A curva de acurácia mostra o progresso da capacidade do modelo em realizar previsões corretas, enquanto a curva de perda ilustra a evolução do erro do modelo.

1.2 Overfitting e Underfitting

- A partir da análise dessas métricas, pode-se identificar problemas como o overfitting (quando o modelo aprende a memorizar os dados de treinamento, mas tem um desempenho ruim em dados não vistos) e o underfitting (quando o modelo não é capaz de aprender corretamente os padrões dos dados, resultando em um desempenho insatisfatório tanto nos dados de treinamento quanto nos de teste).

1.3 Ajustes no Treinamento

- Com base nas observações das métricas, pode ser necessário ajustar a taxa de aprendizado, o número de épocas de treinamento ou outras configurações do modelo, como o número de camadas e neurônios no Perceptron. O ajuste adequado desses parâmetros é essencial para otimizar o desempenho do modelo.

ANÁLISE DE RESULTADOS

Número de Épocas: 100

- Média de Acurácia: 0.9876
- Média de Perda (Loss): 0.0225

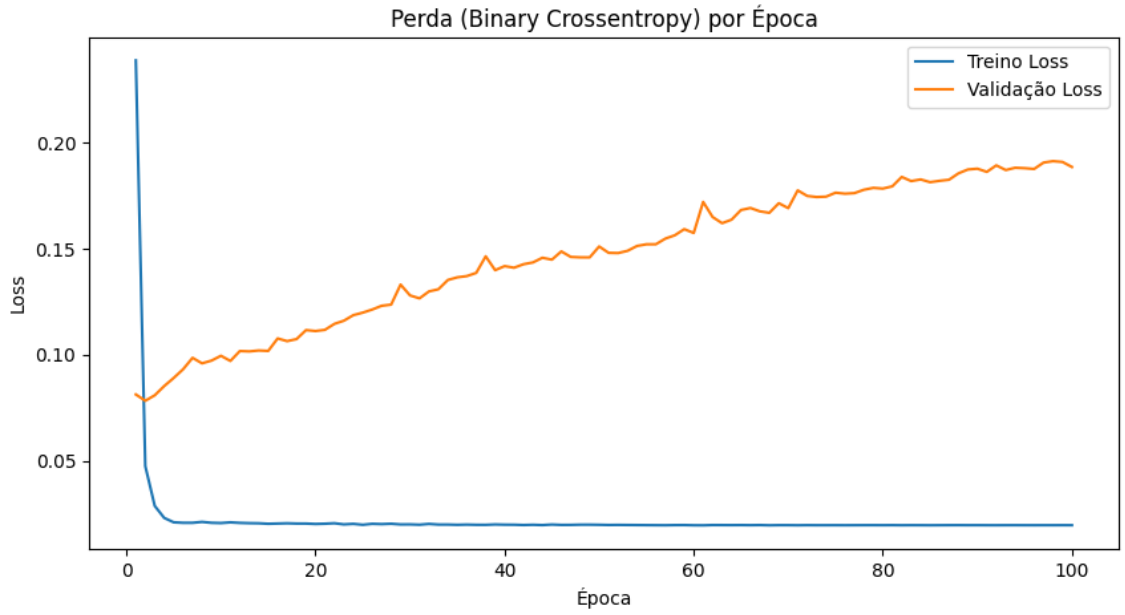

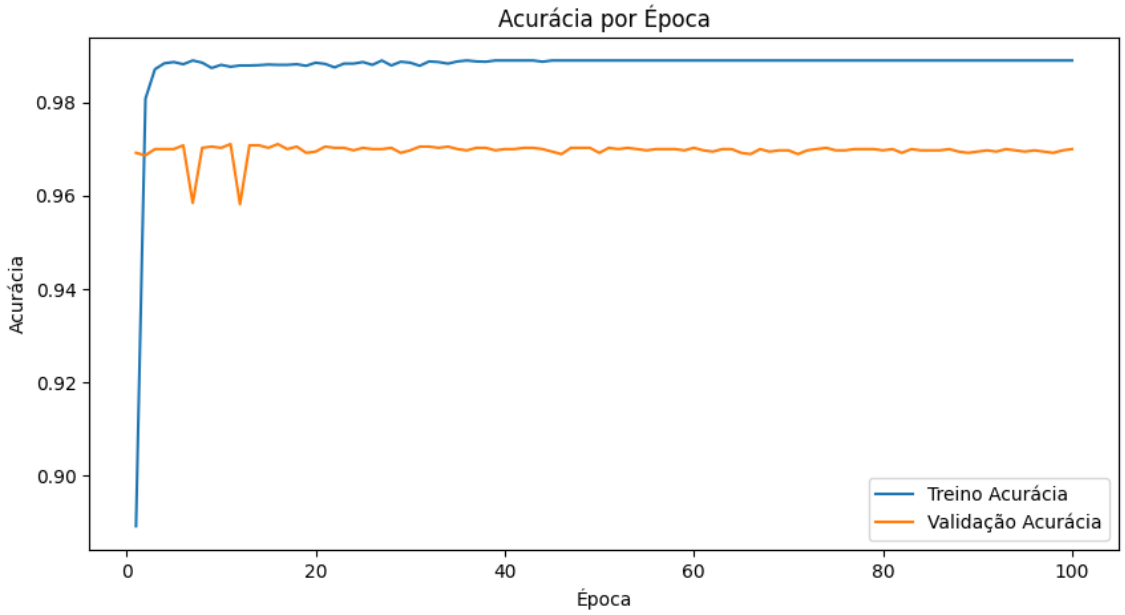

Número de Épocas:200

- Média de Acurácia: 0.9882
- Média de Perda (Loss): 0.0211

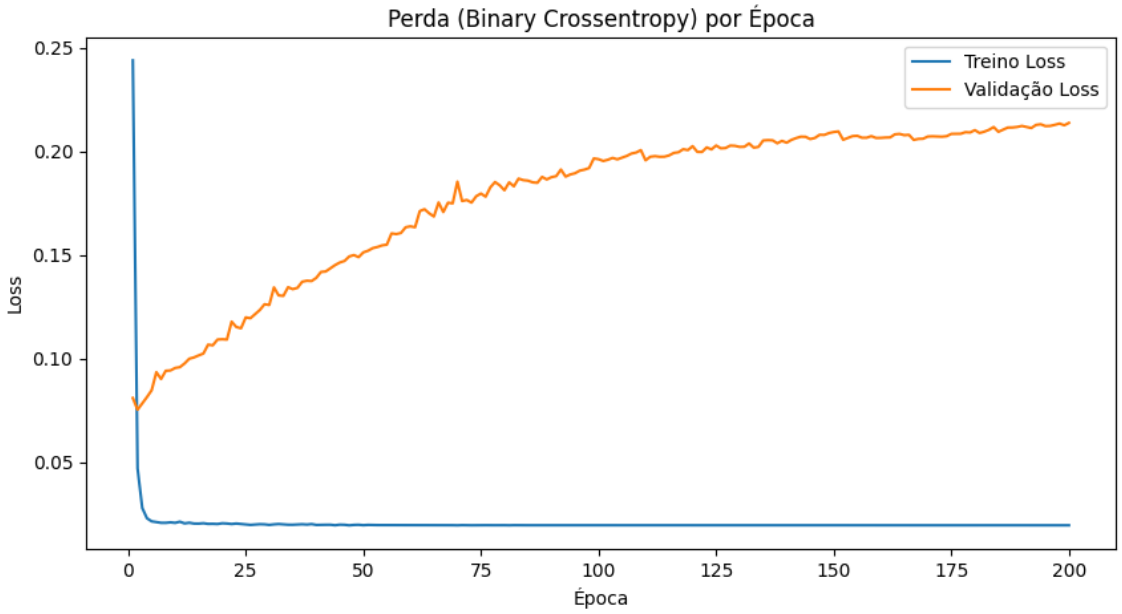

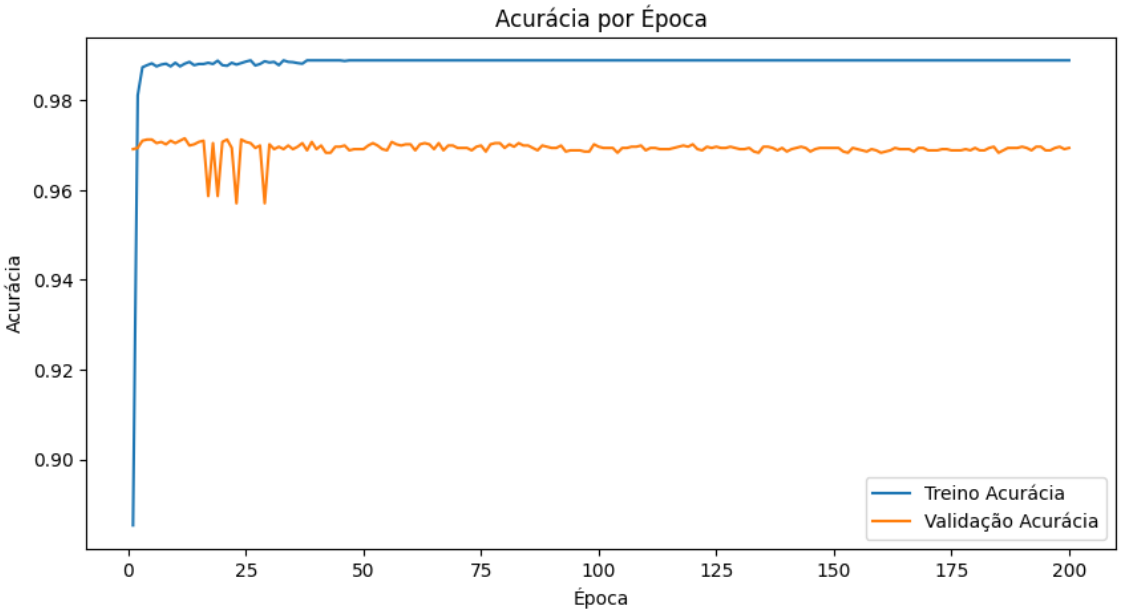

Número de Épocas: 400

- Média de Acurácia: 0.9886
- Média de Perda (Loss): 0.0203

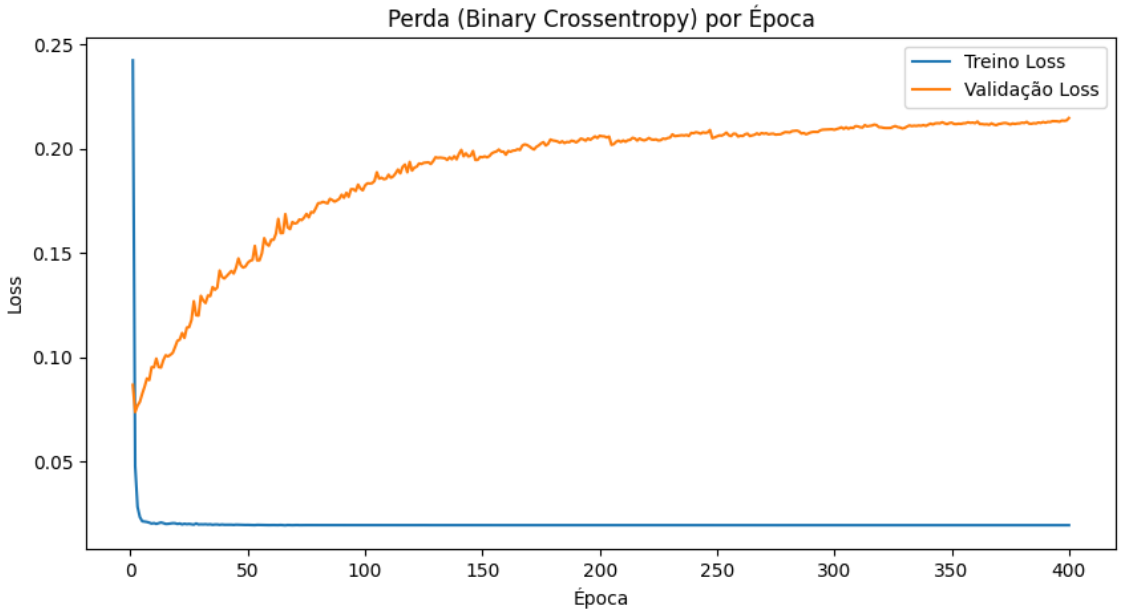

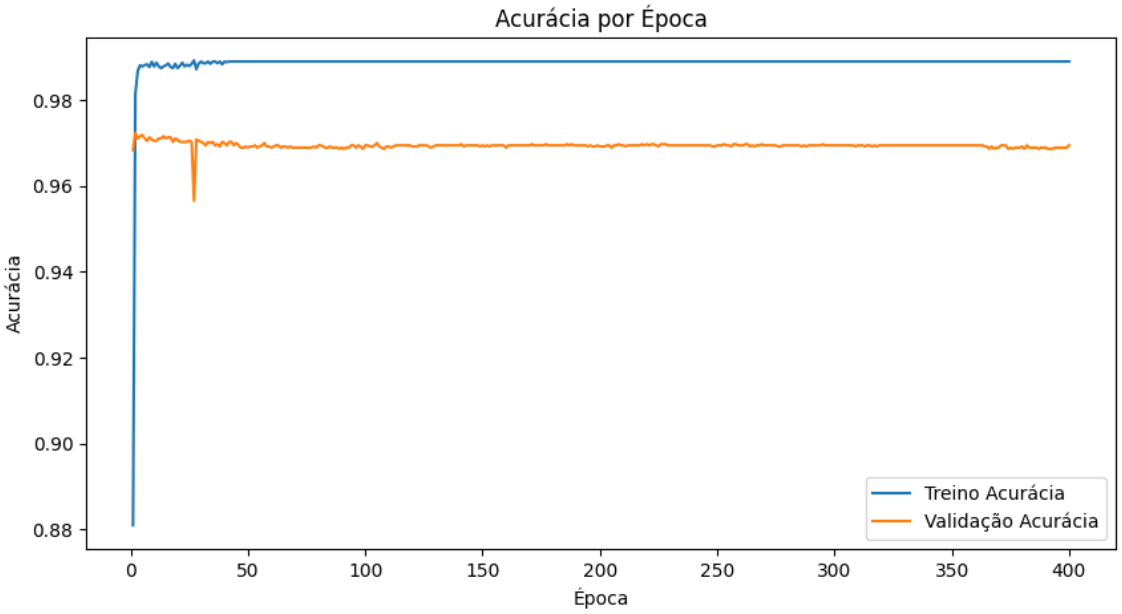

Número de Épocas: 800

- Média de Acurácia: 0.9888
- Média de Perda (Loss): 0.0199

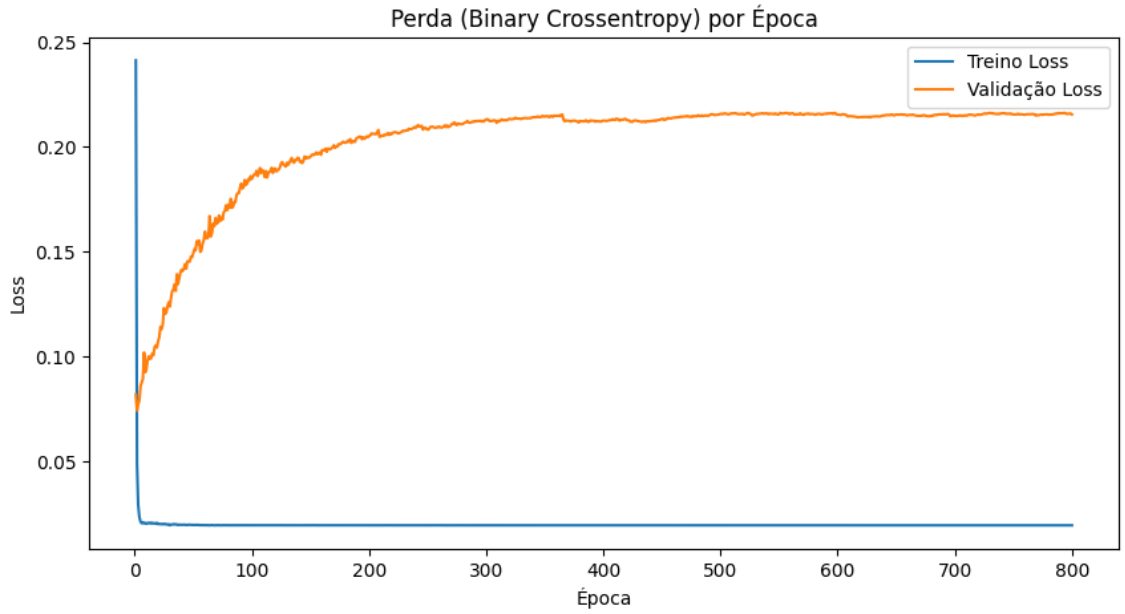

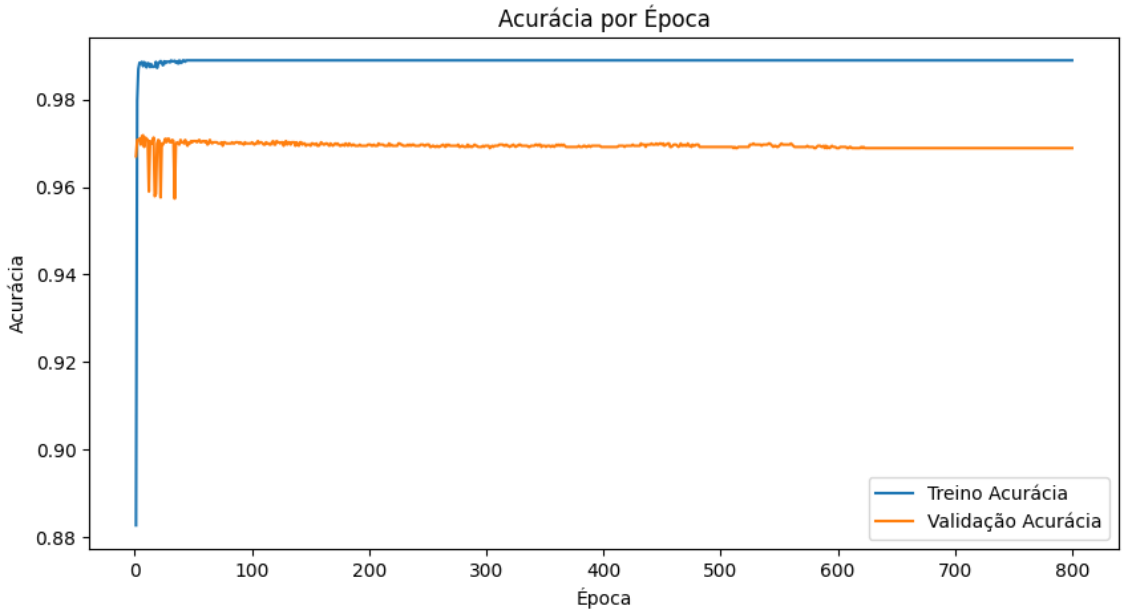

Número de Épocas: 2000

- Média de Acurácia: 0.9889
- Média de Perda (Loss): 0.0197

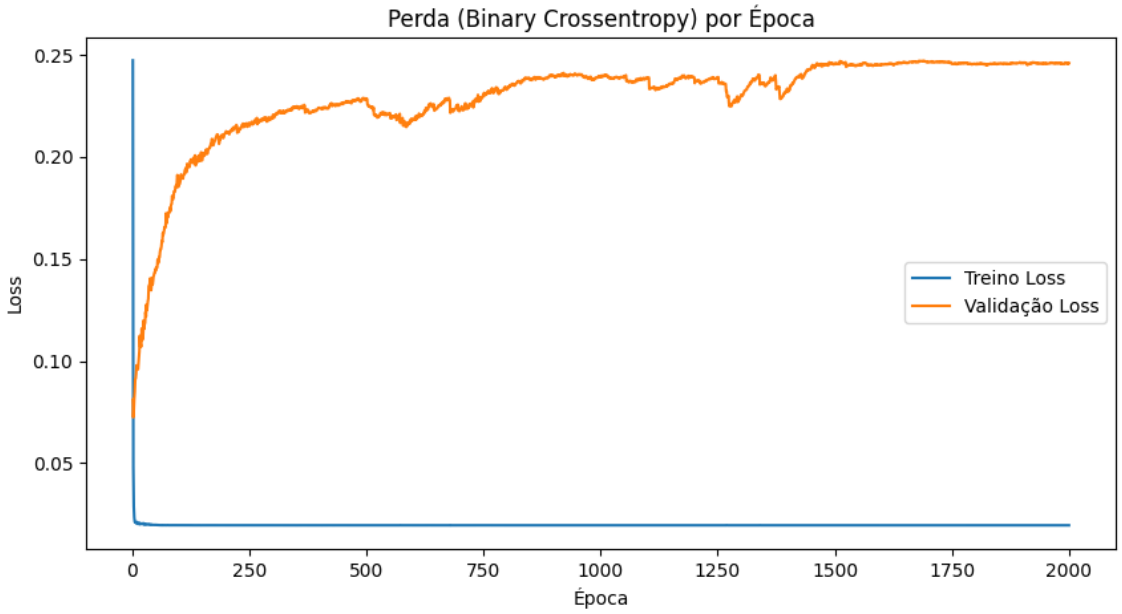

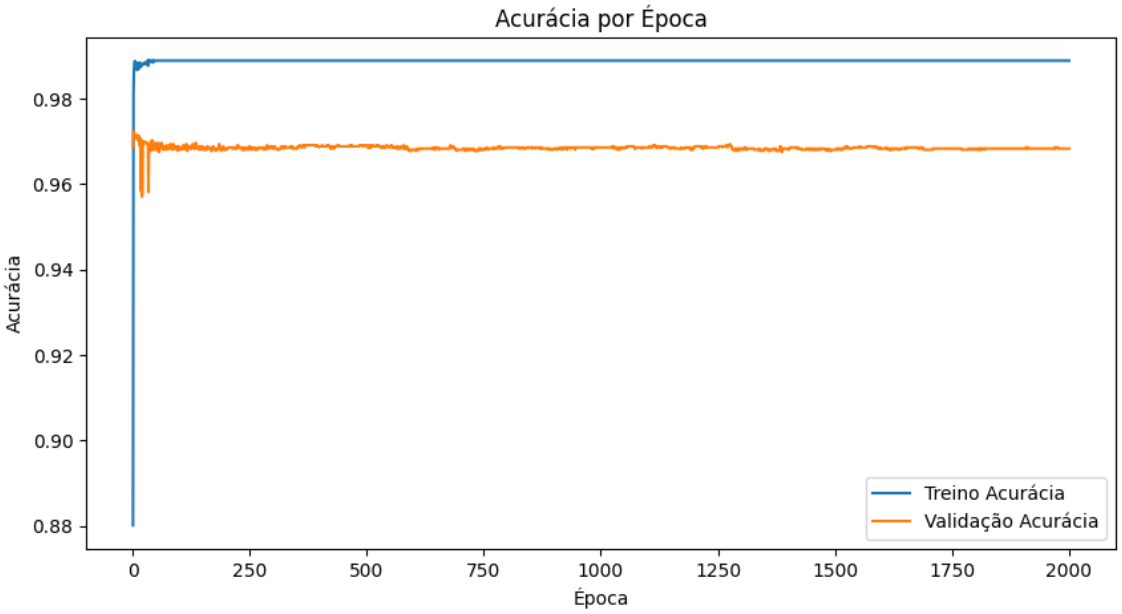

CONSIDERAÇÕES FINAIS

A análise dos resultados demonstra uma evolução significativa do modelo ao longo do treinamento. A curva de aprendizado, marcada pelo aumento gradual da acurácia e pela redução da perda, evidencia que o modelo consegue extrair padrões complexos dos dados e generalizar suas descobertas para novos exemplos. Essa capacidade de aprendizado contínuo e adaptação é crucial para a identificação eficaz de novos ataques de phishing.

A alta precisão do modelo na detecção de e-mails de phishing facilita sua aplicação em diversos sistemas de segurança cibernética. Uma possível implementação seria sua integração em filtros de spam, permitindo a identificação e o bloqueio proativo de e-mails maliciosos. Além disso, o modelo pode ser utilizado para capacitar usuários sobre as características de e-mails de phishing, promovendo maior conscientização sobre esse tipo de ameaça.

Além disso, o modelo pode desempenhar um papel educativo, capacitando usuários ao fornecer percepções detalhados sobre as características mais comuns dos e-mails de phishing. Isso contribui para uma maior conscientização e preparo diante dessa ameaça crescente, fortalecendo tanto a segurança individual quanto coletiva no ambiente digital. Dessa forma, o modelo não apenas protege, mas também promove uma cultura de segurança cibernética mais robusta e informada.